

Original	0.71	0.70	0.70	0.68	0.71
GradDiff	0.28	0.50	0.55	0.59	0.65
NPO	0.27	0.48	0.47	0.55	0.65
SimNPO	0.28	0.57	0.51	0.58	0.64
RMU	0.27	0.40	0.39	0.51	0.70
RR	0.32	0.34	0.38	0.40	0.71
ELM	0.32	0.52	0.49	0.60	0.70
DPO	0.32	0.34	0.39	0.40	0.66
IDK+AP	0.33	0.40	0.36	0.36	0.52
NPO+SAM*	0.26	0.37	0.31	0.44	0.51
NPO+IRM*	0.27	0.33	0.33	0.36	0.56
RMU+LAT*	0.31	0.42	0.37	0.51	0.71
TAR*	0.27	0.33	0.34	0.35	0.68

Unlearned

RobFT (GSM8K)

RobFT (SST2)

RobFT (MNLI)

RobReL